

Trustworthy AI Assignment 3

2021540010 김정민

1. 모델, 데이터셋, 검증 쿼리 설명

모델: 실험에서는 Iris 데이터셋을 분류하기 위한 소규모 FC Network 를 직접 설계하여 학습하였다. 모델 구조는 입력층(4) → Linear(4→8) → ReLU → Linear(8→16) → ReLU → Linear(16→3) → 출력층(3)으로 구성하였다. PyTorch 로 구현 후 ONNX 형식으로 변환하여 Marabou 에 입력하였으며 200 epoch 학습 후 테스트 정확도 100%를 달성하였다.

데이터셋: Iris 데이터셋은 150 개의 샘플과 4 개의 특성으로 구성된 3 클래스 분류 문제이다. Scikit-learn 의 standardScaler 로 정규화 후 입력으로 사용하였으며 8:2 비율로 학습/테스트 데이터를 분류하였다.

검증 쿼리: 테스트 샘플 중 첫 번째 샘플을 기준으로 다음과 같은 검증 쿼리를 설정하였다. 입력 제약의 경우 샘플 x 기준 $\epsilon = 0.01$ 의 L_{∞} -ball 범위를 $x[i] - \epsilon \leq \text{input}[i] \leq x[i] + \epsilon$ 이었다. 출력 제약의 경우 true label 이 아닌 다른 클래스의 출력값이 더 큰 경우를 탐색하여 $\text{output}[j] > \text{output}[\text{true_label}]$ ($j \neq \text{true_label}$)이었으며 검증 목표는 ϵ 범위 내 모든 입력이 동일한 클래스로 분류되는가? 였다.

2. 결과 및 해석

검증 결과 SAT 가 반환되었으며, 검증 시간은 약 24ms 로 매우 빠르게 완료되었다. SAT 는 설정한 출력 제약을 만족하는 입력, 즉 반례가 존재함을 의미한다. 발견된 반례는 아래와 같다.

반례 입력 : [0.3010, -0.5824, 0.5254, -0.0091]

반례 출력: [-4.436, 5.130, -3.922]

원래 샘플 [0.311, -0.592, 0.535, 0.001]과 비교하면 $\epsilon = 0.01$ 범위 내의 매우 작은 perturbation 만으로도 모델의 분류 결과가 바뀔 수 있음이 확인되었다. 이는 해당 모델이 $\epsilon = 0.01$ 범위에서 robust 하지 않음을 수학적으로 증명한 것이다. 테스트 정확도가 100%임에도 불구하고 작은 입력 변화에 취약할 수 있음을 보여주는 결과이다.

3. Marabou 의 장단점

장점: SAT/UNSAT 결과를 통해 신경망의 성질을 수학적으로 증명할 수 있다. 단순히 테스트 기반 평가와 달리 반례가 없음을 완전히 보장한다. 또한 onnx, nnet, pb 등 다양한 형식을 지원하여 pytorch, tensorflow 와 같은 여러 프레임워크와 호환된다. Python api 를 통해 직관적으로 검증 쿼리를 작성할 수 있으며, pip 으로 간단히 설치 가능하다. 소규모 모델에 대해 수십 ms 내에 검증이 완료될 만큼 효율적이라는 장점들이 있다.

단점: 모델 크기가 커질수록 검증 시간이 기하급수적으로 증가한다. 따라서 ResNet 과 같은 대형 모델은 현실적으로 검증이 불가능하다. 일부 활성화 함수나 레이어 타입은 지원하지 않아 모델 설계에 제약이 생긴다. 또한 pip 설치의 간단하나 소스에서 직접 빌드할 경우 boost 등 의존성 문제로 설치가 까다롭다. 실제로 설치를 하는 데 애를 먹은 경험이 있다.